

I302 - Aprendizaje Automático y Aprendizaje Profundo

Trabajo Práctico 4

Tomás González

9 de junio de 2026

Ingeniería en Inteligencia Artificial

Resumen

En este trabajo se estudiaron técnicas de reducción de dimensionalidad y clustering sobre un subconjunto de Fashion-MNIST. Se realizó una inspección exploratoria del dataset, un split estratificado de entrenamiento y evaluación, y se compararon tres representaciones latentes: PCA implementado desde cero, un autoencoder determinístico y un β-VAE. Luego se aplicaron k-Means y GMM diagonal sobre los espacios latentes de PCA y AE, seleccionando configuraciones mediante ganancias decrecientes y Silhouette. El mejor resultado se obtuvo con k-Means sobre PCA usando $K = 10$, con Silhouette 0,1702 y pureza externa ponderada 0,5207. El análisis final muestra que las representaciones latentes recuperan estructura visual útil, aunque las categorías de prendas con formas similares no quedan completamente separadas sin información supervisada.

1. Introducción

El problema abordado consiste en representar y agrupar imágenes de prendas sin utilizar las etiquetas durante el entrenamiento de los modelos. Cada observación es una imagen de 28×28 pixeles en escala de grises, por lo que puede escribirse como un vector $x_i \in \mathbb{R}^{784}$. Las etiquetas reales se usaron únicamente para inspección inicial y evaluación externa de la homogeneidad de los clusters.

El trabajo se organizó en tres etapas. En primer lugar, se verificó la estructura del dataset y se construyó un split estratificado. En segundo lugar, se obtuvieron representaciones de menor dimensión mediante PCA, AE y β-VAE. Por último, se entrenaron k-Means y GMM diagonal sobre los espacios latentes, se eligieron configuraciones con métricas internas y se analizaron los clusters resultantes mediante t-SNE y composición por clase real.

2. Métodos

2.1. Datos y preprocesamiento

El dataset contiene 25000 imágenes con 784 pixeles y una etiqueta entera en $\{0, \ldots, 9\}$. Los valores de pixel estaban normalizados en $[0, 1]$, con media global 0,2866, desvío 0,3533 y sin valores faltantes. Las clases estaban balanceadas: 2500 observaciones por clase.

Se generó un split estratificado 80/20, con 20000 muestras de entrenamiento y 5000 de evaluación. Cada clase aportó 2000 imágenes al conjunto de entrenamiento y 500 al de evaluación. Para PCA se estandarizó cada pixel usando solo estadísticas del conjunto de entrenamiento:

$$x_{ij}^{std} = \frac{x_{ij} - \mu_j}{\sigma_j}. \tag{1}$$

La misma transformación se aplicó luego al conjunto de evaluación y al dataset completo. En los autoencoders se trabajó directamente con los pixeles originales en $[0, 1]$, lo que permite usar una salida Sigmoid.

2.2. Reducción de dimensionalidad

PCA se implementó a partir de la matriz de covarianza de los datos estandarizados:

$$S = \frac{1}{N-1} \bar{X}^T \bar{X}, \qquad S v_j = \lambda_j v_j. \tag{2}$$

Ordenando los autovectores por autovalor decreciente y tomando $U_K = [v_1, \ldots, v_K]$, la proyección y reconstrucción quedan dadas por

$$Z = \bar{X} U_K, \qquad \tilde{X}^{std} = Z U_K^T. \tag{3}$$

Se eligió el menor K que explicara al menos el 90 % de la varianza acumulada. El valor obtenido fue $K = 135$, que reduce la dimensión de 784 a 135.

El autoencoder determinístico usa un encoder y un decoder,

$$z = \phi_e(x; w_e), \qquad \tilde{x} = \phi_d(z; w_d), \tag{4}$$

con dimensión latente $K = 135$ para mantener la comparación con PCA. La arquitectura fue $784 \to 512 \to 256 \to 135 \to 256 \to 512 \to 784$, con activaciones ReLU en capas ocultas y Sigmoid en la salida. Se entrenó durante 150 epochs con Adam, learning rate 10^{-3}, batch size 256 y pérdida MSE:

$$\mathcal{L}_{AE} = \frac{1}{N} \sum_{i=1}^{N} \|x_i - \tilde{x}_i\|^2. \tag{5}$$

También se entrenó un β-VAE, siguiendo la formulación de Auto-Encoding Variational Bayes [1] y la regularización propuesta para β-VAE [2]. El encoder aproxima una distribución latente:

$$q_\phi(z|x) = \mathcal{N}\big(\mu_\phi(x), \mathrm{diag}(\sigma_\phi^2(x))\big), \tag{6}$$

y el entrenamiento minimiza reconstrucción más regularización contra el prior $p(z) = \mathcal{N}(0, I)$:

$$\mathcal{L}_{\beta VAE} = \mathcal{L}_{rec} + \beta\, KL(q_\phi(z|x) \| \mathcal{N}(0, I)), \qquad \beta = 2. \tag{7}$$

Para una posterior diagonal, el término de KL se computó como

$$KL = -\frac{1}{2} \sum_{j=1}^{K} \left(1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2\right). \tag{8}$$

2.3. Clustering y métricas

Para clustering se tomó una muestra estratificada de 3000 imágenes, con 300 ejemplos por clase. Se evaluaron valores $K \in \{5, \ldots, 15\}$ sobre dos espacios: PCA y AE. En PCA se usaron los scores latentes crudos; en AE se estandarizó el latente antes del clustering.

En k-Means se minimizó la inercia,

$$J = \sum_{i=1}^{N} \sum_{j=1}^{K} r_{ij} \|x_i - \mu_j\|^2, \tag{9}$$

con asignaciones duras $r_{ij} \in \{0, 1\}$. En GMM diagonal se modeló la densidad como

$$p(x) = \sum_{j=1}^{K} \pi_j\, \mathcal{N}(x|\mu_j, \Sigma_j), \tag{10}$$

y cada punto se asignó al componente de mayor responsabilidad posterior. El desempeño interno se comparó con Silhouette y con ganancias marginales de la métrica principal: inercia para k-Means y log-verosimilitud promedio para GMM. Para la visualización final se usó una implementación propia de t-SNE aplicada sobre el espacio PCA.

3. Resultados

3.1. Inspección exploratoria

La Figura 1 muestra muestras agrupadas por clase. Se observa variabilidad intraclase, especialmente en prendas superiores, donde cambian mangas, ancho y forma. En cambio, el calzado tiende a presentar siluetas más estables. Esta diferencia anticipa que algunas clases serán más difíciles de separar mediante clustering.



Figura 1: Muestras agrupadas por clase para inspeccionar variabilidad visual intraclase.

La Figura 2 resume cada clase mediante su imagen promedio. Los promedios de calzado y bolsos conservan una forma reconocible, mientras que varias prendas superiores quedan visualmente próximas. Esto sugiere que una parte de la estructura del dataset puede capturarse por forma global, pero que algunas clases comparten patrones visuales similares.

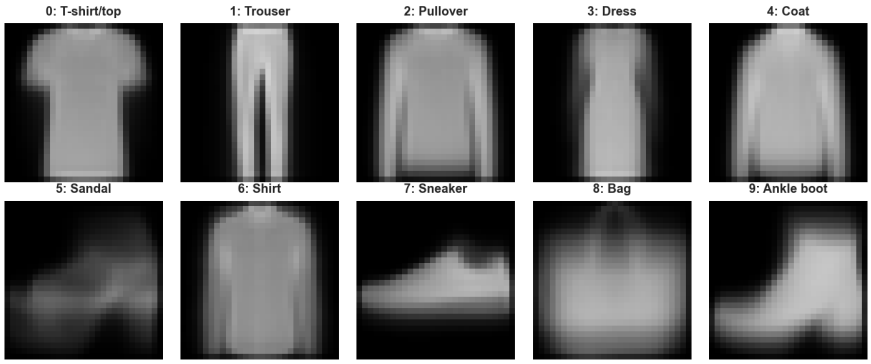


Figura 2: Imagen promedio de cada clase. Los promedios funcionan como prototipos visuales de baja resolución.

3.2. PCA y reconstrucción

La Figura 3 muestra la varianza explicada acumulada. El umbral del 90 % se alcanza con 135 componentes, con una varianza acumulada de 0,9004. La curva crece rápidamente al inicio y luego se aplana, indicando que las primeras componentes capturan la forma global de las prendas y las restantes agregan detalles de menor varianza.

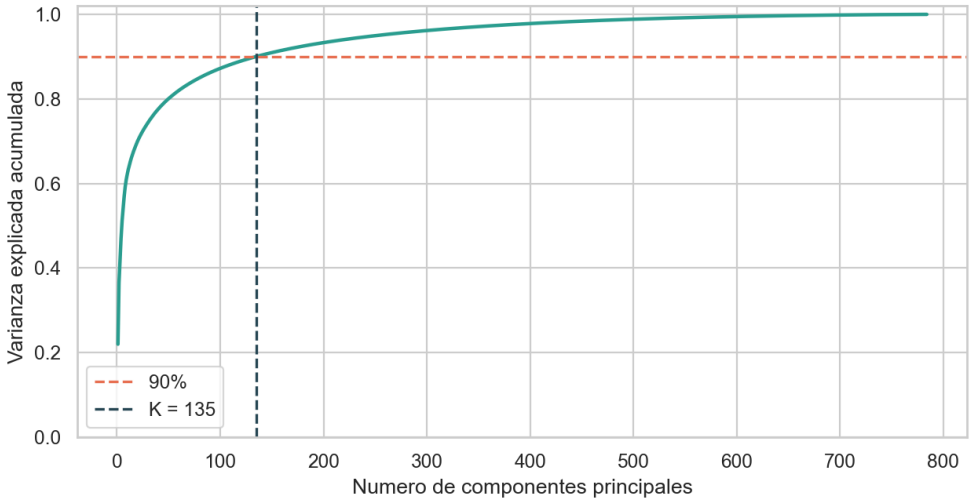


Figura 3: Varianza explicada acumulada por PCA. Se retienen $K = 135$ componentes para superar el 90 %.

Con ese número de componentes, PCA recupera bien la silueta general, aunque suaviza bordes y texturas finas. En la Figura 4 se comparan imágenes originales con sus reconstrucciones. El MSE calculado sobre las diez imágenes mostradas fue 0,00944.

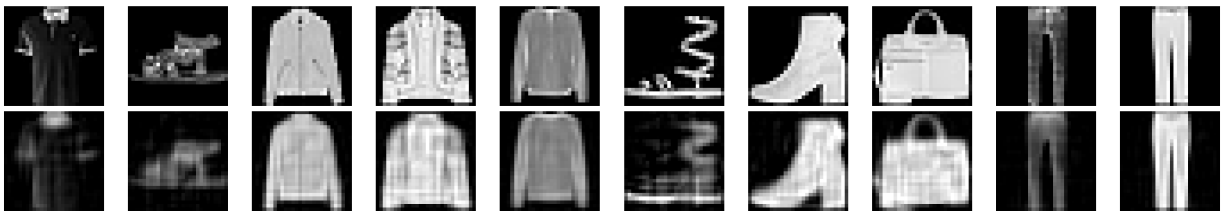


Figura 4: Reconstrucciones obtenidas con PCA usando 135 componentes.

3.3. Autoencoder determinístico y beta-VAE

La curva de entrenamiento del AE se muestra en la Figura 5. Luego de 150 epochs, el MSE de entrenamiento fue 0,00593 y el de validación 0,00776. La cercanía entre ambas curvas indica que el modelo ajustó el patrón principal de las imágenes sin una brecha marcada de sobreajuste.

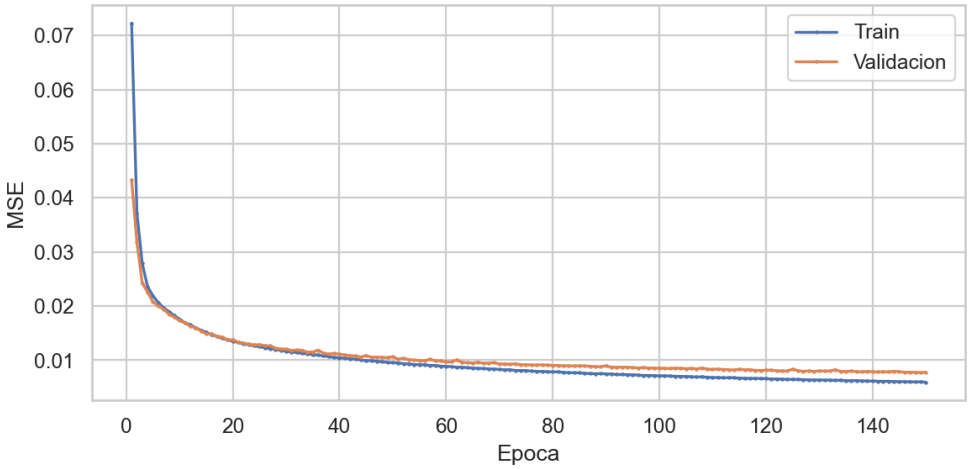


Figura 5: Curvas de entrenamiento y validación del autoencoder determinístico.

La Figura 6 compara reconstrucciones de PCA y AE sobre las mismas diez imágenes. En esta muestra, PCA obtuvo MSE 0,00944 y AE 0,01014. La diferencia es pequeña, pero PCA resultó levemente mejor en el conjunto visual seleccionado.

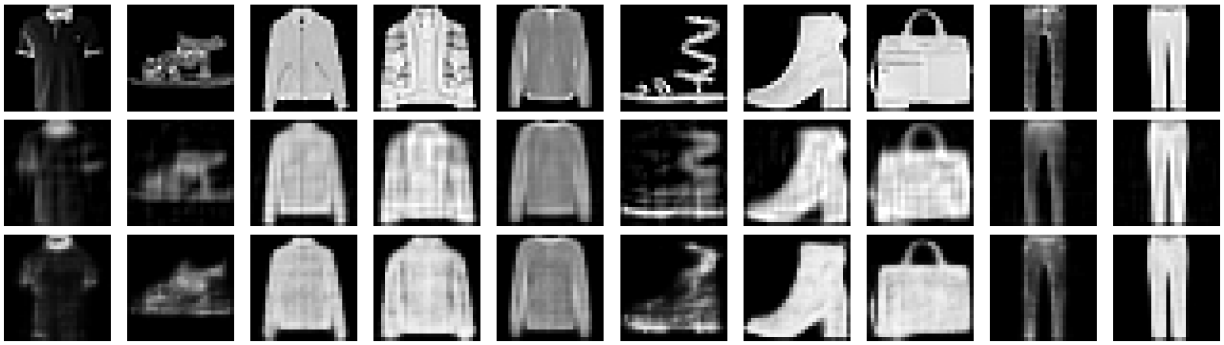


Figura 6: Comparación visual entre imágenes originales, reconstrucciones PCA y reconstrucciones AE.

El β-VAE presentó el comportamiento esperado para un modelo generativo regularizado. En la Figura 7, la pérdida de reconstrucción baja de forma sostenida, mientras que el término KL se mantiene acotado. Al final del entrenamiento, la validación alcanzó loss 250,83, reconstrucción 232,90 y KL 8,96.

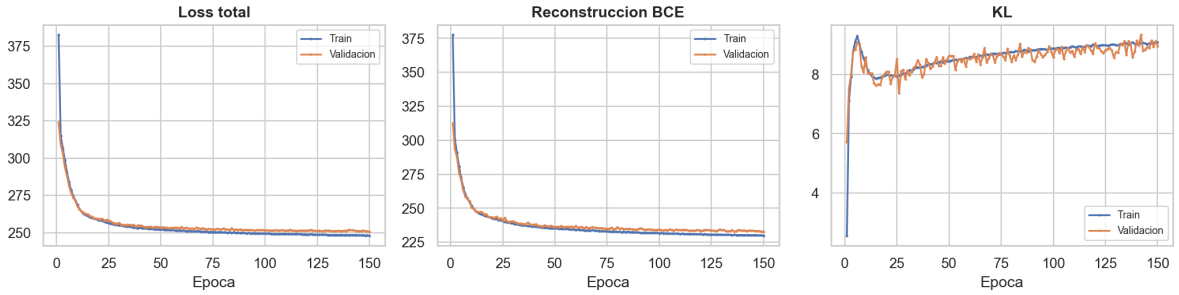


Figura 7: Evolución de loss total, reconstrucción y KL en el β-VAE.

En la Figura 8, el β-VAE reconstruye siluetas coherentes pero más suaves. Su MSE sobre las diez imágenes fue 0,01833, mayor que el de PCA y AE. Esta pérdida de nitidez es consistente con la presión del KL, que ordena el espacio latente a costa de parte de la precisión reconstructiva.

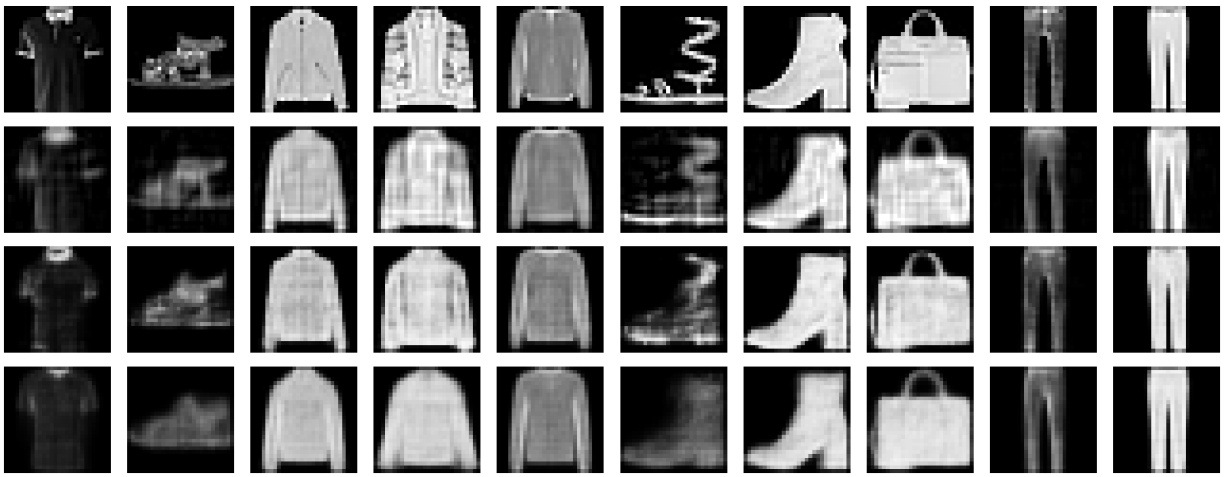


Figura 8: Reconstrucciones de PCA, AE y β-VAE sobre las mismas imágenes.

Para estudiar el espacio latente se promediaron embeddings de cuatro imágenes de la clase Ankle boot. La Figura 9 muestra que ambos modelos producen una bota intermedia, aunque con aspecto suavizado. Este experimento evalúa si el espacio latente permite interpolaciones semánticamente coherentes entre muestras de una misma clase.

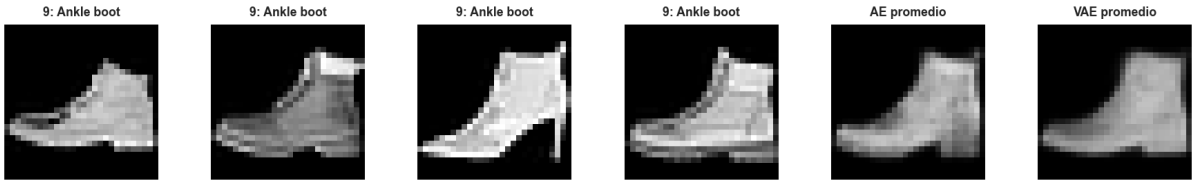


Figura 9: Promedio de embeddings de una misma clase y posterior decodificación con AE y β-VAE.

La Figura 10 muestra decodificaciones de vectores $z \sim \mathcal{N}(0, I)$. El AE puede producir resultados irregulares porque su espacio latente no fue forzado a seguir una normal estándar. El β-VAE es más apropiado para este muestreo, ya que el término KL aproxima sus latentes al prior.

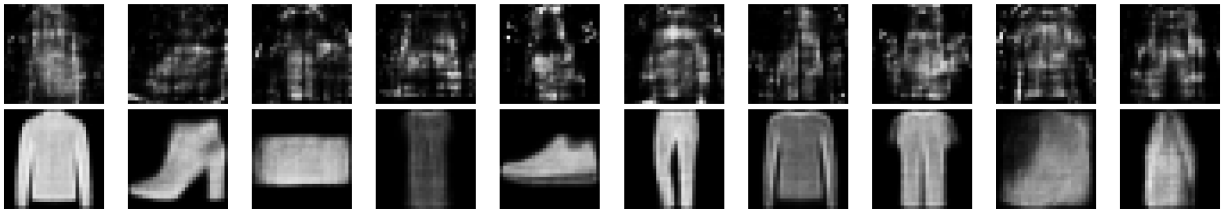


Figura 10: Decodificación de muestras $z \sim \mathcal{N}(0, I)$ para AE y β-VAE.

3.4. Clustering

La Tabla 1 resume la mejor configuración de cada combinación según Silhouette. El mejor valor global fue k-Means sobre PCA con $K = 10$ y Silhouette 0,1702. La coincidencia entre $K = 10$ y la cantidad de clases reales es razonable, pero el valor de Silhouette sigue siendo moderado; por lo tanto, no hay una separación geométrica perfecta.

Tabla 1: Mejor configuración por Silhouette para cada método y espacio latente.

Método	Espacio	Mejor K	Silhouette
k-Means	PCA	10	0.1702
k-Means	AE	6	0.1312
GMM diagonal	PCA	7	0.0533
GMM diagonal	AE	5	0.1418

Las Figuras 11 y 12 muestran las curvas para el espacio PCA. En k-Means la inercia disminuye al aumentar K, pero las ganancias marginales se reducen y el máximo de Silhouette aparece en $K = 10$. En GMM, la log-verosimilitud promedio mejora con más componentes, pero el Silhouette permanece bajo. Esto evidencia que ajustar mejor la densidad no implica necesariamente obtener particiones más separadas.

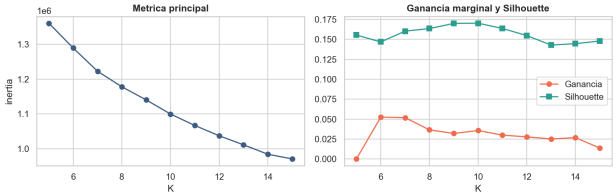


Figura 11: k-Means sobre el espacio PCA.

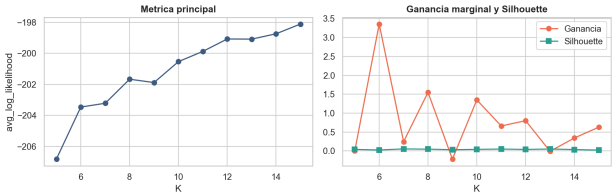


Figura 12: GMM diagonal sobre el espacio PCA.

3.5. Visualización y homogeneidad de clusters

Para el análisis final se seleccionó k-Means con $K = 10$ sobre PCA. La Figura 13 muestra la proyección t-SNE coloreada por cluster y la Figura 14 muestra la misma proyección coloreada por clase real. El valor final de $KL(P\|Q)$ en t-SNE fue 1,6169. La correspondencia de etiquetas reales es: 0=T-shirt/top, 1=Trouser, 2=Pullover, 3=Dress, 4=Coat, 5=Sandal, 6=Shirt, 7=Sneaker, 8=Bag y 9=Ankle boot.

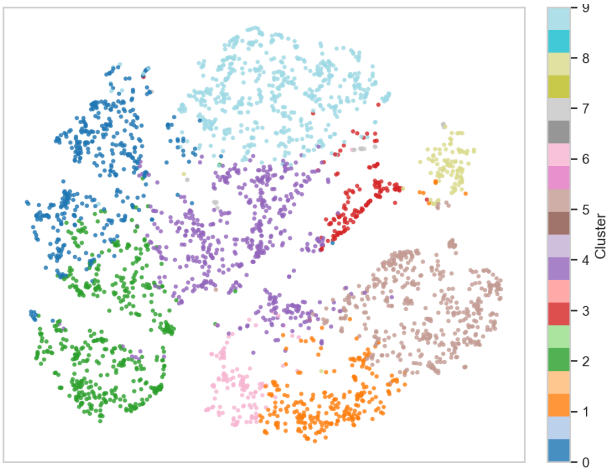


Figura 13: t-SNE del latente PCA coloreado por cluster de k-Means.

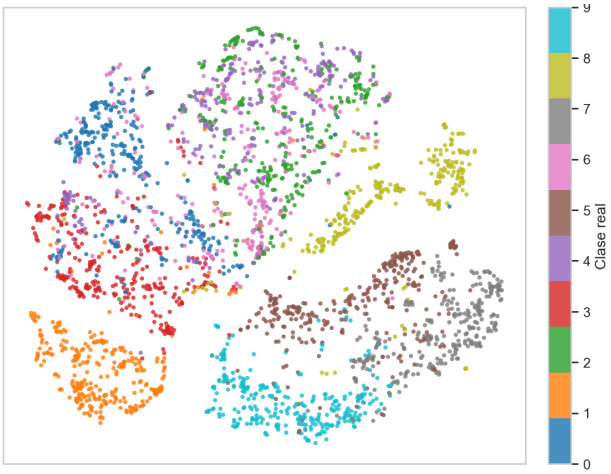


Figura 14: Misma proyección t-SNE coloreada por etiqueta real.

La comparación entre ambas figuras muestra que los clusters capturan regiones coherentes del mapa, pero no coinciden perfectamente con las clases reales. La Tabla 2 cuantifica esta mezcla. Los clusters 3 y 8 están dominados por Bag, y el cluster 6 por Ankle boot, con purezas altas. En cambio, los clusters 4 y 9 son grandes y heterogéneos: mezclan principalmente clases de prendas superiores, donde las siluetas son más parecidas. La pureza externa ponderada fue 0,5207 y la pureza promedio por cluster fue 0,6373.

Tabla 2: Resumen de homogeneidad para k-Means sobre PCA con $K = 10$.

Cluster	Cantidad	Clase dominante	Pureza
0	410	T-shirt/top	0.493
1	254	Ankle boot	0.701
2	463	Trouser	0.579
3	140	Bag	0.886
4	519	Shirt	0.227
5	456	Sneaker	0.555
6	124	Ankle boot	0.879
7	21	Bag	0.667
8	96	Bag	1.000
9	517	Coat	0.387

La Figura 15 confirma que los tamaños no son uniformes: van desde 21 hasta 519 muestras. La Figura 16 muestra la composición relativa de clases por cluster. Allí se observa que algunos clusters son muy concentrados, mientras que otros distribuyen su masa entre varias clases cercanas. Esto justifica que el resultado sea útil como agrupamiento exploratorio, pero insuficiente para reemplazar una clasificación supervisada.

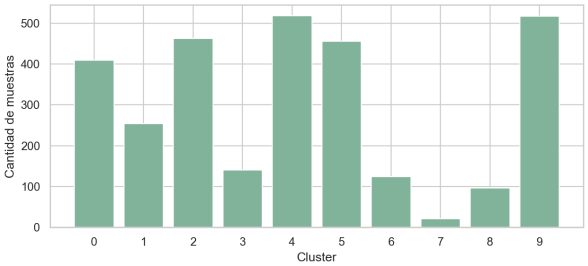


Figura 15: Tamaño de los clusters seleccionados.

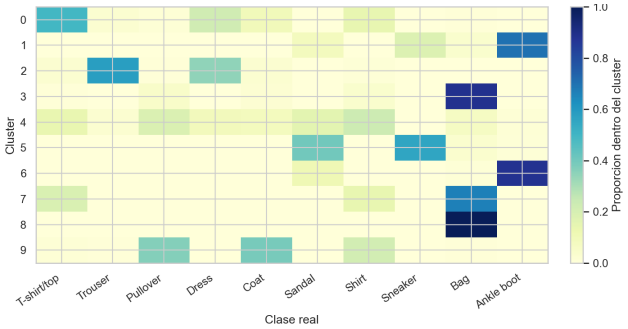


Figura 16: Composición relativa de clases en cada cluster.

4. Conclusiones

PCA resultó una representación sólida para este dataset: con 135 componentes conservó el 90 % de la varianza y produjo reconstrucciones competitivas. El AE alcanzó un error de validación bajo, aunque su latente no mejoró el clustering respecto de PCA. El β-VAE generó un espacio latente más adecuado para muestrear desde una normal estándar, pero sus reconstrucciones fueron más suaves por la regularización KL.

En clustering, k-Means sobre PCA fue la alternativa más consistente. El mejor valor de K por Silhouette fue 10, coincidente con el número de clases reales, pero la pureza ponderada de 0,5207 muestra que la estructura no supervisada recupera solo parcialmente las etiquetas. El análisis con t-SNE y la composición por cluster indica que las clases con siluetas más distintivas forman grupos más homogéneos, mientras que varias prendas superiores se mezclan. En conjunto, las representaciones latentes son útiles para exploración y compresión, pero la separación entre categorías de Fashion-MNIST no queda completamente resuelta sin información supervisada.

Referencias

[1] D. P. Kingma y M. Welling. *Auto-Encoding Variational Bayes*. 2013.

[2] I. Higgins et al. *β-VAE: Learning Basic Visual Concepts with a Constrained Variational Framework*. 2017.