

Universidad de
SanAndrés

I302 - Aprendizaje Automático y Aprendizaje Profundo

1er Semestre 2025

Trabajo Práctico 4

Fecha de entrega: Martes 9 de Junio, 23:59 hs.

Formato de entrega: Los archivos desarrollados deberán entregarse en un archivo comprimido (.zip) a través del Campus Virtual, utilizando el siguiente formato de nombre: *Apellido_ Nombre_ TP4.zip*. Se aceptará únicamente un archivo por estudiante y debe contener por lo menos los siguientes elementos:

```
Apellido_Nombre_TP4.zip/
|- data/
|- Apellido_Nombre_Informe_TP4.pdf
|- Apellido_Nombre_Notebook_TP4.ipynb
```

- **Informe:** Debe incluir todos los aspectos teóricos, decisiones metodológicas, visualizaciones, análisis y conclusiones. El objetivo es que el informe contenga toda la explicación principal del trabajo. Se puede hacer referencia al notebook con frases como "Ver sección X del notebook para la implementación". El informe debe entregarse utilizando el archivo `template_informe.tex` provisto y no debe exceder las 10 páginas.
- **Notebook:** Debe contener el código utilizado, experimentos, análisis exploratorio, gráficos y el proceso completo de procesamiento y modelado. Sirve como respaldo técnico del informe y debe estar ordenado y bien documentado. Se recomienda modularizar el código en archivos `.py` cuando sea posible.

Trabajo Práctico 4: Aprendizaje No-Supervisado

El objetivo de este trabajo es desarrollar y evaluar métodos de aprendizaje no supervisado. **No se permite usar librerías de machine learning como scikit-learn o PyTorch para implementar los métodos solicitados, a menos que sea pedido explícitamente en el enunciado del ejercicio.**

1. **Inspección de los datos** El dataset *fashion_ mnist_ subset.csv* contiene 25000 imágenes de 28×28 pixeles en escala de grises, junto con sus etiquetas de clase. Para realizar un análisis exploratorio de estos datos, se proponen los siguientes puntos:

   a) Implementar una función que pueda graficar un número arbitrario de imágenes del dataset. Mostrar un ejemplo de un gráfico con 15 imágenes seleccionadas de manera aleatoria. Esta función va a ser necesaria a lo largo de todo el trabajo, por lo que se deberá ir adaptando de acuerdo a las necesidades que vayan surgiendo.

   b) Realizar un análisis exploratorio enfocado en la distribución de clases en los datos. Para tener una mejor noción de la variabilidad de las muestras, graficar muestras agrupadas por clase, para al menos 5 clases.

   c) Realizar un split de datos estratificado para conformar un conjunto de entrenamiento y otro de evaluación, en donde los datos de evaluación sean el 20 % del total.

2. **Reducción de dimensionalidad**

   a) Implementar una función para estandarizar los datos, y otra para realizar Principal Component Analysis (PCA). Estandarizar y aplicar PCA sobre los datos de entrenamiento. Con la transformación aprendida previamente reducir la dimensionalidad de los datos de evaluación.

   b) Realizar un gráfico que muestre la varianza explicada acumulada en función del número de componentes. Conservar el número de componentes que aseguren explicar el 90 % de la varianza de los datos. Utilizando la función aprendida en el punto 1.a), realizar un gráfico comparativo entre las imágenes originales y la reconstrucción partiendo del número de componentes determinado anteriormente.

   c) Entrenar un modelo autoencoder deterministico (AE) utilizando la librería PyTorch para armar y entrenar las redes neuronales involucradas (la red de encoder y la de decoder). Para hacer una comparación justa, la dimensión latente debe ser la misma que la obtenida en el PCA.

   d) Una vez desarrollado el AE, compare la calidad de las imágenes reconstruidas con las obtenidas mediante PCA en el inciso anterior, utilizando 10 imágenes tomadas aleatoriamente del conjunto de validación del AE.

   e) Para los siguientes puntos, en lugar de trabajar con las imágenes originales vamos a trabajar con su versión de menor dimensionalidad en el espacio latente del PCA y AE obtenida en el inciso anterior para acelerar el procesamiento. Aplique la transformación para todos los datos, tanto de entrenamiento como de validación usando la transformación aprendida con los datos de entrenamiento.

   f) **(Opcional)[Hacerlo perdona HASTA dos errores en otros puntos]** Entrenar un β-Variational Autoencoder (β-VAE) usando PyTorch, con la misma dimensión latente K

que se utilizó para el PCA y el AE. La loss debe combinar reconstrucción y regularización del latente. Para esto, cite un paper y explíquelo brevemente en el informe.

Reportar las curvas de loss separando reconstrucción y KL. Comparar la calidad de las reconstrucciones del VAE con las del PCA y AE obtenidas en los puntos anteriores, sobre las mismas 10 imágenes del conjunto de validación. Sobre los espacios latentes del AE y del VAE realizar los siguientes experimentos:

1) Seleccionar 3–4 imagenes del conjunto de validación de la misma clase, calcular el embedding de cada una y promediarlos. Decodificar el embedding promedio con AE y con VAE. Visualizar las imagenes de referencia y la reconstrucción del promedio por modelo.
2) Muestrear vectores $z \sim \mathcal{N}(0, I)$ con dimensión K y decodificarlos con AE y con VAE. Visualizar las imagenes de referencia y la reconstrucción del promedio por modelo.

Discutir las diferencias observadas entre AE y VAE en ambos experimentos.

3. **Clustering**

En este punto, trabaje con 3000 puntos (muestra estratificada). Puede utilizar más si lo desea y la capacidad computacional lo permite.

a) Desarrollar una funcion que implemente el algoritmo k-Means. Probar con valores de K dentro del rango de $[5, 15]$.

b) Desarrollar una funcion que implemente el algoritmo GMM. Probar con valores de K dentro del rango de $[5, 15]$.

c) Analizar el desempeño para distintos valores de K. Utilizar el método de *ganancias decrecientes*, junto con el método de *Silhouette score*. Graficar tanto la ganancia marginal como el valor de Silhouette score en función de K. ¿Qué se puede concluir sobre K observando estas curvas? ¿Cómo se relaciona el numero de K encontrado con el número de clases presentes en los datos? Justificar.

d) Del mejor valor de K resultante del análisis anterior graficar todas las muestras con un color para cada cluster en 2D utilizando una implementación propia de t-SNE aplicada sobre el espacio latente del PCA aprendido en el punto 2. ¿Qué puede decir de la calidad de los clusters de acuerdo a la cantidad de muestras que agrupa y la homogeneidad de clases en cada cluster? Realizar los gráficos/tablas/análisis que crea conveniente para fundamentar su respuesta.